

Knowledge Distillation dla klasyfikacji obrazów

CIFAR-100: porównanie baseline, embedding KD i logit KD

Yaroslav Kolesnik, Pavel Yurashevich, Huz Nazar

7 maja 2026

- Celem projektu było sprawdzenie, czy mniejszy model może poprawić wyniki dzięki destylacji wiedzy z większego modelu.
- Skupiliśmy się na klasyfikacji obrazów oraz porównaniu kilku wariantów uczenia studenta.
- Ze względu na ograniczenia czasowe i obliczeniowe finalne eksperymenty wykonano na zbiorze **CIFAR-100**, a nie na Tiny ImageNet.

Pytanie badawcze: czy embedding distillation rzeczywiście pomaga, czy lepszym kierunkiem jest klasyczna destylacja logitów?

Zbiór danych:

- CIFAR-100
- 100 klas
- obrazy o rozmiarze 64x64 po przeskalowaniu

Ustawienia treningu:

- augmentacja: `basic = RandomCrop + HorizontalFlip`
- batch size: 96
- optymalizator: AdamW
- learning rate: $3e-4$
- teacher: 15 epok
- student: 20 epok

Metryki: Accuracy oraz Macro-F1.

Teacher:

- ResNet-50
- inicjalizacja wagami ImageNet
- najlepszy wynik walidacyjny: **81.82%**

Studenci:

- ResNet-18
- tiny_cnn

Porównywane warianty:

- baseline: tylko Cross-Entropy
- embed+cls: strata klasyfikacyjna + dopasowanie embeddingow
- embed only
- logit+cls
- embed+logit+cls

Jak wyglądała destylacja

Embedding distillation:

- student i teacher dostają ten sam obraz
- teacher zwraca logity oraz embedding
- student zwraca logity oraz embedding
- embedding studenta jest porównywany z embeddingiem teacher'a

W finalnych wynikach:



- nie użyto PCA bottleneck w końcowym notebooku ($\text{DISTILL_DIM} = 0$)
- dla embedding KD zastosowano MSE + normalizację embeddingów
- dla logit KD użyto temperatury $T = 4$

Wniosek praktyczny: sprawdziliśmy nie tylko sam embedding KD, ale też czy lepiej działa destylacja logitów.


Model	Wariant	Test Acc	Macro-F1
ResNet-18	baseline	58.32%	58.13%
ResNet-18	embed+cls	59.08%	58.90%
tiny_cnn	baseline	27.71%	25.47%
tiny_cnn	embed+cls	27.46%	25.08%

- Dla **ResNet-18** embedding distillation dała tylko niewielką poprawę: **+0.76 p.p.**
- Dla **tiny_cnn** nie zaobserwowano poprawy.
- Sama hipoteza, że *embedding distillation* wyraźnie pomaga słabszym modelom, nie potwierdziła się.

Porównanie modeli



Ablacje dla ResNet-18





- **embed only** praktycznie się załamał: około **0.7%** accuracy
- **logit+cls** okazał się najlepszy: **61.10%**

Wyniki ablacji (liczbowe)

Wariant	Val Acc	Test Acc	Test F1
baseline_cls	57.96%	58.32%	58.13%
embed_plus_cls	57.90%	59.08%	58.90%
embed_only	0.74%	0.73%	0.40%
logit_plus_cls	60.22%	61.10%	60.98%
embed_logit_cls	59.82%	60.86%	60.79%


- Najlepiej wypada **logit+cls**; dodanie embedding loss do logit KD nie daje dodatkowego zysku.
- **embed only** potwierdza, że sam sygnał embeddingowy bez CE nie uczy poprawnej klasyfikacji.

Wizualizacja embeddingów




- Wizualizacje mają charakter **jakościowy**, a nie rozstrzygający.
- Nie widać wyraźnego, stabilnego upodobnienia embeddingów studenta do teacher'a po samym embedding KD.
- To zgadza się z wynikami liczbowymi: sygnał z embeddingów okazał się słaby.

Krzywe uczenia (Accuracy)




- Wykres pokazuje metrykę **val accuracy** w kolejnych epokach dla baseline i embed+cls.

Krzywe uczenia: ablacje (ResNet-18)



- Widać wyraźnie, że **logit_plus_cls** i **embed_logit_cls** dominują przez większość treningu.

Krzywe uczenia (Strata)



- Dla baseline raportujemy `val_loss`, a dla destylacji `val_total`.

• Kształt krzywych potwierdza stabilną konwergencję, ale bez wyraźnego

- Embedding distillation nie przyniosła oczekiwanej, wyraźnej poprawy.
- Dla ResNet-18 zysk był niewielki, a dla tiny_cnn nie było poprawy.
- Najlepszy wynik uzyskał wariant **logit+cls**, czyli klasyczna destylacja logitów.
- Oznacza to, że w naszym ustawieniu **logity teacher'a okazały się bardziej użyteczne niż same embeddingi końcowe**.
- Ze względu na ograniczenia czasowe nie wdrażaliśmy bardziej zaawansowanej destylacji warstw pośrednich, która mogłaby być skuteczniejsza.

Dziękujemy za uwagę